

AgriFlow — Detailed Architecture & Methodology

Food Security Intelligence Platform for Sub-National Indonesia

AgriFlow Team — PIDI DIGDAYA × Hackathon 2026, Bank Indonesia

Revisi: Mei 2026

Abstract

AgriFlow adalah platform intelijen ketahanan pangan sub-nasional dengan tiga fungsi inti: **Deteksi** (anomali harga), **Prediksi** (peramalan harga), dan **Distribusi** (pencocokan surplus-defisit antar-kabupaten). Dokumen ini menjelaskan, untuk setiap fungsi: metodologi yang dipakai, alasan pemilihan metode, cara kerja, efektivitas, serta evaluasi dan validasi terhadap data nyata BPS/PIHPS Jawa Timur. Setiap pilihan metode didukung literatur terkini (2021–2026). Prinsip rancangan kami: *honest engineering* — memilih metode yang tepat untuk skala saat ini (38 kabupaten Jawa Timur), bukan yang paling rumit, dan menyatakan keterbatasan secara eksplisit.

1 Ikhtisar Sistem

AgriFlow memproses tiga lapis nilai di atas satu sumber data bersama (harga PIHPS harian, produksi/konsumsi/populasi BPS per-kabupaten):

1. **Deteksi** — mengidentifikasi anomali harga (lonjakan/anjlok) dari deret harga harian.
2. **Prediksi** — meramalkan harga 30 hari ke depan dengan foundation model time-series.
3. **Distribusi** — mencocokkan kabupaten surplus dengan kabupaten defisit melalui *matching engine* 4-lapis yang sadar masa-simpan, jarak jalan nyata, dan keadilan.

Ketiganya terhubung: prediksi dan deteksi memberi sinyal dini, distribusi menindaklanjuti dengan alokasi yang efisien sekaligus adil.

Positioning. AgriFlow adalah *alat bantu keputusan untuk pemerintah* (Bapanas/Pemda), **bukan** marketplace komersial. Ini membedakannya dari platform seperti eNAM [15] (lelang harga India) atau MealConnect [16] (penyelamatan pangan AS), dan dari B2B agritech Indonesia yang gagal karena margin tipis (mis. TaniHub [17]). Karena insentif kami adalah KPI ketahanan pangan + stabilitas harga + keadilan — bukan margin per-transaksi — dimensi *equity* antar-kabupaten menjadi tujuan utama, bukan afterthought.

2 Distribusi — Matching Engine

2.1 Formulasi masalah

Diberikan himpunan node *surplus* S dan *defisit* D per komoditas, kami mencari alokasi yang memaksimalkan kesejahteraan agregat dengan bobot keadilan. Karena *kedua sisi menilai pasangan melalui satu fungsi skor bersama* (bukan preferensi ordinal independen seperti pasar dua-sisi), setting yang tepat adalah **centralized bipartite assignment dengan equity weighting** — seorang perencana terpusat (Bapanas/Pemda), bukan pasar terdesentralisasi. Pandangan ini sejalan dengan kerangka *optimal transport/assignment* di mana preferensi berasal dari surplus bersama [1]. Kami secara sadar *tidak* mengklaim "stable matching Gale–Shapley pemenang Nobel": teorema stabilitas Roth–Sotomayor [2] mensyaratkan preferensi ordinal independen, yang tidak berlaku di sini.

2.2 Cara kerja: arsitektur 4-lapis

- **Layer 0 — Tier classification.** Tiap kabupaten ditandai Tier 1 (8 kota IHK, harga harian PIHPS, confidence *HIGH*) atau Tier 2 (kab non-IHK, mingguan, *MEDIUM*).
- **Layer 1 — Hard constraints.** Filter cepat: kecocokan komoditas, jarak $\leq$ maksimum (jarak jalan nyata OSRM, fallback haversine), umur panen $\leq$ masa-simpan, volume minimum, no self-match, mode darurat, override Pemda, prioritas Bulog.
- **Layer 2 — Multi-objective scoring.** Skor 0–100 dari 5 dimensi berbobot: Distance 22%, Volume 22%, Price 22%, Perishability 18%, Climate 16% (*weighted-sum scalarization*).
- **Layer 3 — Equity-weighted allocation.** Final = Base $\times m(\text{IPM})$, dengan *m equity multiplier* untuk kabupaten ber-IPM rendah; alokasi via modified Gale–Shapley (Tier 1 $\leftrightarrow$ Tier 1) atau greedy berprioritas-equity.

2.3 Alasan pemilihan metode

Weighted-sum scalarization dipilih karena interpretable dan murah secara komputasi; kami menyadari ia hanya menjangkau solusi Pareto *supported* [3], dan menyediakan 3 skema bobot (default/Ramadan/import) sebagai mitigasi parsial. **Equity multiplier** post-score dipilih demi transparansi bagi audiens kebijakan; literatur menunjukkan formulasi in-objective (penalty factor [4]) atau Gini-derived [5] dan leximin maximin [6] lebih *principled* secara teori — ini kami tetapkan sebagai arah v2.

2.4 Efektivitas, evaluasi, dan validasi

Kami memvalidasi nilai keadilan secara **empiris** dengan membandingkan AgriFlow terhadap empat baseline (*pure-greedy* = efisiensi, *uniform & proportional-to-deficit* = acuan pemerataan, dan varian *smoothed*) pada **dua skenario terkontrol** yang sengaja dirancang untuk mengisolasi efek keadilan: satu *pasokan melimpah* dan satu *pasokan langka* (*shock* La Niña yang menghapus surplus tiga sentra beras). Metrik: cakupan (volume-weighted), Gini (dari kurva Lorenz, weighted), Atkinson ($\epsilon=1$), dan *leximin* (fulfillment kabupaten terburuk).

Skenario / Strategi	Coverage	Gini	Atkinson($\epsilon=1$)	Sampang	Bangkalan
<i>Pasokan melimpah (surplus > deficit)</i>					
pure_greedy	0.890	0.093	0.113	1.00	1.00
uniform	0.993	0.008	0.094	1.00	1.00
proportional	0.993	0.007	0.094	1.00	1.00
AgriFlow	0.880	0.099	0.114	1.00	1.00
<i>Pasokan langka (shock La Niña; deficit > surplus)</i>					
pure_greedy	0.665	0.302	0.984	0.00	0.20
uniform	0.627	0.252	0.186	1.00	1.00
proportional	0.702	0.159	0.137	0.78	0.78
AgriFlow	0.665	0.290	0.938	1.00	1.00

Temuan kunci (jujur). Saat pasokan melimpah, equity nyaris tak berdampak (kab termiskin sudah terlayani; Gini AgriFlow $\approx$ greedy). *Nilai sebenarnya muncul saat langka*: greedy menelantarkan Sampang (0%) dan Bangkalan (20%), sedangkan **AgriFlow menjamin keduanya 100% dengan biaya cakupan agregat nol** ($0.665 = 0.665$), Gini turun $0.302 \rightarrow 0.290$. Klaim presisi kami: "*AgriFlow memprioritaskan kabupaten terlemah saat pasokan langka,*" bukan "*menurunkan ketimpangan secara umum.*"

Dua jenis validasi (tidak dicampur). (i) *Perbandingan baseline* di atas dijalankan pada skenario terkontrol untuk mengisolasi efek keadilan secara apples-to-apples. (ii) Secara *terpisah*, engine dijalankan *end-to-end* pada **data BPS/PIHPS Jawa Timur asli per-kabupaten** (tahun

acuan 2022) untuk 5 komoditas (beras, cabai merah & rawit, bawang merah & putih) — membuktikan pipeline bekerja pada angka nyata, bukan sintetis. Seluruh hasil reproducible dan teruji otomatis (404 tes; 403 lulus, 1 di-skip — lihat §7).

2.5 Mengapa metode ini tepat

Untuk konteks perencanaan terpusat dengan satu fungsi kesejahteraan, assignment terbobot lebih tepat dan dapat diaudit daripada mekanisme pasar dua-sisi. Pendekatan Food Drop berbasis *power-of-two-choices* dengan jaminan aproksimasi [7] adalah arah pelengkap v2 (menambah *provable bound* yang saat ini belum ada).

3 Prediksi — Peramalan Harga (TimesFM)

3.1 Metode dan cara kerja

Peramalan harga 30 hari memakai **TimesFM 2.0** [9], *decoder-only foundation model* time-series Google yang dilatih pada ~ 100 miliar titik data dan mampu *zero-shot* (tanpa pelatihan per-komoditas). Input: deret harga harian PIHPS per kota/komoditas; output: titik ramalan + interval prediksi (P10/P90). Prophet dan XGBoost dipakai sebagai *baseline* pembanding.

3.2 Alasan pemilihan & efektivitas

Bukti agri-spesifik terkini menunjukkan foundation model time-series **secara konsisten mengungguli** metode klasik (ARIMA/Prophet) maupun ML (XGBoost) untuk harga komoditas pertanian [8], membalik anggapan lama bahwa "metode sederhana menang untuk komoditas." Pada leaderboard zero-shot independen (GIFT-Eval), keluarga TimesFM berada di tier teratas baik untuk akurasi titik (MASE) maupun probabilistik (CRPS) [9]. Kami *tidak* mengklaim TimesFM mutlak terbaik — Chronos-2/Moirai-2.0 bersaing ketat.

3.3 Evaluasi dan validasi

Evaluasi memakai *rolling-origin backtest* dengan MAPE & MASE serta kalibrasi cakupan interval P10/P90. Keterbatasan jujur: konfigurasi *univariate* melewati variabel eksogen. Untuk beras/cabai Indonesia, literatur menunjukkan indikator ENSO/iklim [11] dan musim hari raya [12] *material* terhadap akurasi — karenanya v2 akan menambahkan kovariat (kalender Ramadan, indeks ENSO) yang secara teknis dapat di-*retrofit* ke foundation model [10].

4 Deteksi — Anomali Harga

4.1 Metode dan cara kerja

Deteksi anomali memakai pendekatan **Seasonal-Hybrid ESD (S-H-ESD)** [14]: (1) *deseasonalize* deret (buang trend + komponen musiman), lalu (2) terapkan statistik *robust* median + MAD pada *residual*, dengan flag $|r - \tilde{r}| > k \cdot 1.4826 \cdot \text{MAD}$. Ditambahkan *persistence threshold* (flag hanya jika bertahan ≥ 2 observasi) dan *floor* skala untuk komoditas bervolatilitas-rendah (beras).

4.2 Alasan pemilihan: mengapa BUKAN deep learning

Benchmark TSAD yang andal (NeurIPS 2024) menunjukkan bahwa di bawah evaluasi yang adil, detektor transformer (mis. AnomalyTransformer/TranAD) *tidak* secara reliabel mengungguli metode statistik sederhana — keunggulan mereka sebagian artefak metrik *point-adjustment* yang bias [13]. Untuk konteks kebijakan di mana *interpretability* menentukan, memilih S-H-ESD adalah keputusan yang *defensible*, bukan malas.

4.3 Efektivitas dan validasi

Pada harga PIHPS Jawa Timur 2021–2025, upgrade ke S-H-ESD memangkas jumlah flag $\sim 60\%$ ($14.261 \rightarrow 5.686$) dengan menyaring *noise* musiman rutin sambil **mempertahankan kejadian nyata**: lonjakan bawang merah Probolinggo $+73\text{--}81\%$ pada April 2024 (pasca-Idul Fitri) tetap terdeteksi sebagai event *sustained*. Validasi kontekstual: anomali teratas konsisten dengan kalender hari raya dan pola pasar nyata. Keterbatasan: *binning* musiman bulanan mengaburkan pergeseran kalender Hijriah (~ 11 hari/tahun); trend rolling-median tertinggal ~ 15 observasi saat *regime shift*.

5 Data & Validasi Empiris

Engine berjalan pada **data nyata BPS/PIHPS Jawa Timur per-kabupaten**: produksi (BPS Jatim), konsumsi per-kapita (Susenas BPS — untuk beras bahkan *per-kabupaten*, bukan asumsi nasional), populasi (BPS), dan harga harian PIHPS 2021–2025. Surplus/defisit diturunkan sebagai *food balance*: $\text{surplus_deficit} = \text{produksi} - \text{konsumsi}$, dengan satuan/konversi terdokumentasi ($\text{kuintal} \div 10 = \text{ton}$; padi GKG $\times 0.6286 = \text{beras giling}$). Lima komoditas inti tervalidasi nyata (beras, cabai merah & rawit, bawang merah & putih) pada tahun acuan konsisten 2022. Seluruh pipeline reproducible dan diuji otomatis (404 tes; 403 lulus, 1 di-skip).

6 Keterbatasan & Roadmap (Phase 3)

- Data nyata 5 komoditas, tahun 2022; daging & telur menunggu data produksi per-kab lengkap.
- Konsumsi cabai/bawang memakai rata-rata nasional $\times$ populasi (proxy); beras sudah per-kab.
- Equity multiplier post-score (heuristik) $\rightarrow$ migrasi ke penalty/leximin in-objective [4, 6].
- Tanpa *provable bound* $\rightarrow$ adopsi power-of-two-choices [7].
- Prediksi univariate $\rightarrow$ tambah kovariat eksogen (ENSO/Ramadan) [11, 10].
- Skala provinsi (Jatim) siap; nasional 514 kab perlu spatial partitioning + precompute.

7 Pengujian & Validasi

7.1 Kenapa: keputusan kebijakan butuh bukti yang dapat direproduksi

AgriFlow bukan rekomendasi belanja biasa; outputnya menggerakkan alokasi pangan antar-kabupaten yang menyentuh kabupaten IPM-rendah. Untuk sistem keputusan seperti ini, klaim “adil” dan “robust” tidak boleh berhenti di narasi. Tiga alasan teknis menuntut suite uji otomatis yang tebal. *Pertama, reproducibility*: seluruh pipeline food-balance (produksi — konsumsi, konversi satuan BPS, surplus/defisit per-kabupaten) harus menghasilkan angka yang sama di mesin yang berbeda, sehingga uji data-nyata mengunci angka acuan 2022 sebagai *golden numbers*. *Kedua, regression-safety*: equity multiplier, bobot skor Layer 2, dan ambang anomali adalah parameter kebijakan yang sensitif; perubahan kecil tanpa sengaja dapat membalik pemenang alokasi, sehingga setiap seam (mis. `equity_fn`) diuji *default-preserving* agar refactor tidak diam-diam menggeser hasil. *Ketiga, robustness terhadap kondisi nyata Indonesia*: literatur evaluasi deteksi anomali menunjukkan bahwa metrik yang tampak baik pada benchmark sintetis sering runtuh pada data lapangan dan flagging musiman [13]; karena itu deteksi anomali AgriFlow diuji secara adversarial, bukan hanya pada lonjakan buatan. Filosofi ini sejalan dengan *honest-engineering*: kami menguji justru pada kasus yang paling mungkin memperlakukan sistem, mengikuti pelajaran dari kegagalan agritech yang mengabaikan kondisi tepi pasar [17].

7.2 Apa: enam kategori uji

Suite memuat **404 tes terkumpul** dalam tujuh kelompok fungsional, dijalankan lintas-OS pada CI (matriks pytest). Tabel 1 merangkum cakupan.

Table 1: Kategori uji AgriFlow dan apa yang dijaga.

Kategori	#	Yang divalidasi
Unit per-layer (L0–L3)	73	Tier IPM (16), constraint jarak/perishability (19), skor weighted-sum (24) [3], alokasi equity-weighted (14) [4]
24 skenario edge-case (A–F)	27+	Volume, spasial, temporal, disrupti, politis, kualitas; memetakan kejadian nyata Jatim (lihat Tabel 2)
Validasi data nyata BPS/PIHPS	57	Food-balance beras (16) & hortikultura 2022 (18), pipeline reproducible (23)
Deteksi anomali harga	49	S-H-ESD pada residual deseasonalized [14]; adversarial musiman [13]
Forecast & API	40	Endpoint forecast/anomali; fallback bila TimesFM/FastAPI absen [9]
Baseline & equity	39	Perbandingan greedy/uniform/proporsional vs AgriFlow (24) + skenario supply-constrained (15) [5, 6]
Ingest & integrasi	73	Loader DB (11), ingest harga PIHPS (33), jarak jalan OSRM (9), bot WhatsApp (20)

Inti dari lapisan kedua adalah **24 skenario edge-case** (kelas `TestA1...TestF2`), masing-masing memetakan satu kondisi operasional nyata Jawa Timur, bukan kasus buatan: lonjakan Ramadan, erupsi Semeru di Lumajang, banjir Madura, kenaikan BBM, dan kontrak Bulog. Tabel 2 memuat seluruhnya satu baris per skenario.

Table 2: 24 skenario edge-case dan kondisi nyata yang dimodelkan.

Kode	Nama	Yang divalidasi
A1	One-to-many	Satu surplus memasok banyak defisit; split volume konsisten
A2	Many-to-one	Surabaya 200t cabai dipasok dari banyak sentra
A3	Volume mismatch drastis	Surplus 5t vs defisit 100t (ratio 5%) → flag warning
A4	Zero demand	Surplus tanpa defisit komoditas → peluang ekspor eksternal
B1	Cross-tier	Tier 1 (Kota Kediri) surplus → Tier 2 (Sam-pang) defisit

Kode	Nama	Yang divalidasi
B2	Long distance	Pacitan→Banyuwangi ~400km melampaui batas 200km → ditolak
B3	Cluster Madura	Empat kab Madura ditangani sebagai klaster spasial
C1	Ramadan spike	Pra-Idul Fitri H-14, bobot temporal disesuaikan
C2	Post-harvest	Pasca-panen: margin perishability menyempit
C3	Stale data	Data >24 jam → flag <code>STALE_DATA_24H</code> , confidence turun
C4	Holiday calendar	Event spike non-Ramadan ter-deteksi engine (multi-holiday)
D1	Banjir rute	Hujan 75mm rute Kediri-Surabaya → climate score 0.3
D2	Komoditas rusak	Cabai harvest_age=4 (max 5) → perish score 0
D3	Harga anomali	Outlier > 3σ dari ambang statis per komoditas → exclude (pra-filter z-score, bukan S-H-ESD)
D4	Erupsi gunung	Lumajang erupsi Semeru → unreachable, semua match ditolak
D5	Banjir multi-kab	Bojonegoro+Lamongan+Tuban (sentra padi) banjir bersamaan
D6	Route blackout	Rute ditutup (mudik/demo/maintenance) → re-route/reject
E1	Equity tie-break	Skor seri → IPM lebih rendah menang [4]
E2	Pemda override	<code>do_not_export_cabai_merah=True</code> dihormati
E3	Bulog priority	Surplus beras di kab procurement Bulog → 60% reserve
E4	Import policy	Kebijakan impor bawang aktif → bobot price diturunkan
E5	BBM naik	BBM +20% → biaya logistik naik, max_distance menyusut
E6	Contract reserve	Kontrak swasta (MoU Carrefour, gula Indofood) dipotong dulu
F1	Grade substitution	Surplus premium boleh memenuhi demand medium (opt-in)
F2	Demand segmentation	HORECA & RETAIL untuk komoditas+kab sama hidup berdampingan; <code>segment_multiplier</code> mengubah ranking

7.3 Hasil

Pada commit terakhir suite menjalankan **403 tes lulus, 1 di-skip** (404 terkumpul), konsisten lintas-OS di CI. Satu skip itu jujur kami catat: `test_timesfm_importorskip` memakai `pytest.importorskip` sehingga uji spesifik-TimesFM dilewati bila pustaka berat tersebut tidak terpasang di runner CI; jalur forecasting tetap diuji lewat fallback statistik dan kontrak API [9]. Dua hasil validasi paling load-bearing:

Equity hanya terbukti saat pasokan langka, dan diperoleh tanpa biaya efisiensi. Pada skenario *abundant* (surplus > defisit), greedy maupun AgriFlow sama-sama menutup Sampang

dan Bangkalan 100%; tidak ada trade-off untuk diukur. Perbedaan baru muncul pada skenario *supply-constrained* (La Niña: banjir simultan Ngawi+Madiun+Bojonegoro, surplus turun ke 3962t vs defisit 5249t, ratio 0.754). Di sana strategi greedy murni **menelantarkan Madura**: Sampang terlayani 0% dan Bangkalan 20%. AgriFlow mengangkat keduanya ke **100%** sambil mempertahankan *coverage agregat yang identik* (0.6649 untuk kedua strategi) dan menurunkan ketimpangan (Gini 0.3017 $\rightarrow$ 0.2905). Artinya equity multiplier membeli keadilan pada **biaya efisiensi nol** dalam skenario ini, sebuah klaim yang diuji, bukan diasumsikan [4, 5, 6]. Kami sengaja tidak mengklaim keunggulan equity pada kondisi pasokan melimpah, karena di sana tidak ada yang harus dikorbankan.

Deteksi anomali sadar-musiman, bukan sekadar ambang 3σ . Detektor S-H-ESD menandai penurunan harga tajam (uji DROP, mis. anjlok $\sim 60\%$ terhadap rolling median) dan lonjakan ekstrem, namun yang lebih penting: *pola musiman murni tidak ikut ter-flag*. Pada uji seasonal, sinus musiman beramplitudo $\sim 30\%$ (mis. siklus harga jelang Lebaran) menghasilkan residual mendekati nol setelah deseasonalisasi sehingga tidak memicu false positive, sementara anomali genuine yang ditumpangkan di atas pola musiman tetap terdeteksi [14]. Inilah sifat yang ditekankan literatur benchmark anomali sebagai pembeda detektor yang andal di lapangan dari yang hanya bagus di kertas [13].

Singkatnya, suite ini mengubah klaim arsitektur menjadi properti yang dapat diaudit ulang: setiap angka equity dan setiap perilaku anomali di dokumen ini memiliki tes yang menjaganya tetap benar pada commit berikutnya.

Lampiran A — Ringkasan Matematis

Seluruh formula yang *load-bearing* di sistem, untuk acuan cepat (turunan lengkap di luar cakupan dokumen ini):

Komponen	Formula	Peran
Skor Layer 2	$\text{Base} = 100 \sum_i w_i s_i,$ (0.22, 0.22, 0.22, 0.18, 0.16)	w = weighted-sum: Distance, Volume, Price, Perishability, Climate
Alokasi Layer 3	$\text{Final} = \text{Base} \times m(\text{IPM})$	equity-weighted assignment
Equity multiplier m	$\text{IPM} < 68 \rightarrow 1.30; 68-72 \rightarrow 1.15;$ $72-78 \rightarrow 1.05; \geq 78 \rightarrow 1.00$	tier keadilan (kuartil IPM Jatim 2024)
Flag anomali	$ r - \tilde{r} > k \cdot 1.4826 \cdot \text{MAD}(r), \quad k=3,$ residual r	S-H-ESD pada residual deseasonalized
Food balance	surplus/defisit = produksi – konsumsi	turunan node surplus & defisit
Konversi satuan	kuintal $\div 10$ = ton; padi GKG $\times 0.6286$ = beras giling	normalisasi data BPS

Catatan: metrik evaluasi (Gini dari kurva Lorenz, Atkinson dengan parameter inequality-aversion ε , leximin, serta MAPE/MASE untuk forecasting) memakai definisi standar; pemilihannya dibahas di seksi terkait. Equity multiplier saat ini *step-function* (interpretable bagi audiens kebijakan); migrasi ke bentuk *smooth*/in-objective adalah arah v2 (§Keterbatasan).

References

- [1] A. Galichon. *The unreasonable effectiveness of optimal transport in economics*. arXiv:2102.03875, 2021.
- [2] A. E. Roth, M. Sotomayor. *Two-Sided Matching: A Study in Game-Theoretic Modeling and Analysis*. Cambridge University Press, 1990.
- [3] C. Bazgan et al. *The power of the weighted sum scalarization for approximating multiobjective optimization problems*. arXiv:1908.01181, 2021.
- [4] M. Firouz et al. *On the equity-efficiency trade-off in food-bank network operations*. arXiv:2111.05839, 2021.
- [5] D. Alem, A. Caunhye, A. Moreno. *Revisiting Gini for equitable humanitarian logistics*. 2021.
- [6] M. Hakimifar, V. Hemmelmayr, F. Tricoire. *A lexicographic maximin approach to the selective assessment routing problem*. arXiv:2201.09599, 2022.
- [7] M. Diaby et al. *Automating Food Drop: The Power of Two Choices for Dynamic and Fair Food Allocation*. ACM EC, arXiv:2406.06363, 2024.
- [8] Wang, Zhang. *The Promise of Time-Series Foundation Models for Agricultural Forecasting: Evidence from Commodity Prices*. arXiv:2601.06371, 2026.
- [9] A. Das et al. *A decoder-only foundation model for time-series forecasting (TimesFM)*. arXiv:2310.10688, 2023 (TimesFM-2.5, GIFT-Eval 2026).
- [10] *ChronosX / TFMAdapter: extending time-series foundation models with exogenous covariates*. arXiv:2509.13906, 2025.
- [11] Al Anshari. *Forecasting Rice Price Volatility in Indonesia: Integrating ENSO Indicators with Machine Learning*. IJSDP, 2025.
- [12] *Multi-Commodity Food Price Forecasting Ahead of Eid Al-Fitr in Indonesia*. MALCOM Indonesian J. of ML & CS, 2026.
- [13] Q. Liu, J. Paparrizos. *The Elephant in the Room: Towards A Reliable Time-Series Anomaly Detection Benchmark*. NeurIPS 2024 (Datasets & Benchmarks).
- [14] J. Hochenbaum, O. Vallis, A. Kejariwal. *Automatic Anomaly Detection in the Cloud Via Statistical Learning (Seasonal-Hybrid ESD)*. arXiv:1704.07706, 2017.
- [15] *e-NAM (Electronic National Agriculture Market), India* — pasar lelang terpadu; tinjauan dampak & tantangan (systematic literature review).
- [16] *MealConnect (Feeding America)* — platform pencocokan penyelamatan pangan donor-bank, AS.
- [17] *TaniHub Group collapse* — pelajaran dari kegagalan agritech B2B terbesar Indonesia (margin tipis, ekspansi berlebih).